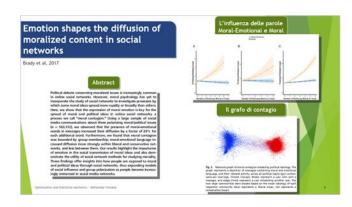
Polarizzazione delle opinioni sui Social Network

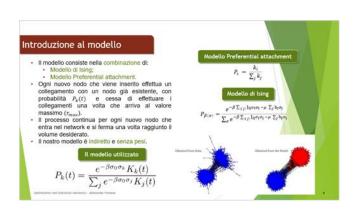
Confronto tra modello e realtà

Introduzione

Presentazione dei dati



Il modello usato



L'accordo con i dati



Alla ricerca di ulteriori modelli



Machine Learning Google BERT

Machine Learning - Google BERT

- Abbiamo sviluppato diversi modelli di Machine Learning con l'obbiettivo di assegnare un Orientation ad un qualunque utente estraneo al training set. In particolare mi sono concentrato sullo studio dei modello Google BERT.
- BERT è l'acronimo di Bidirectional Encoder Representations from Transformers ed è un tipo di rete neurale pre-trainata molto utilizzata nell'ambito del linguaggio naturale. Il modello presenta circa 110 milloni di parametri ed è stato pre-trainato con un dataset di circa 3,3 Miliardi di parole.
- È stato quindi necessario andare a modificare i dati di input così da farli combaciare con quelli richiesti da BERT.



mural retrork and big bata - Alektandar Fontane

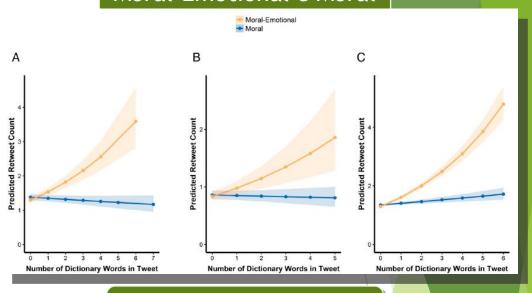
Emotion shapes the diffusion of moralized content in social networks

Brady et al. 2017

Abstract

Political debate concerning moralized issues is increasingly common [in online social networks. However, moral psychology has yet to incorporate the study of social networks to investigate processes by which some moral ideas spread more rapidly or broadly than others. Here, we show that the expression of moral emotion is key for the spread of moral and political ideas in online social networks, a process we call "moral contagion." Using a large sample of social media communications about three polarizing moral/political issues (n = 563,312), we observed that the presence of moral-emotional words in messages increased their diffusion by a factor of 20% for each additional word. Furthermore, we found that moral contagion was bounded by group membership; moral-emotional language increased diffusion more strongly within liberal and conservative networks, and less between them. Our results highlight the importance of emotion in the social transmission of moral ideas and also demonstrate the utility of social network methods for studying morality. These findings offer insights into how people are exposed to moral and political ideas through social networks, thus expanding models of social influence and group polarization as people become increasingly immersed in social media networks.

L'influenza delle parole Moral-Emotional e Moral



Il grafo di contagio

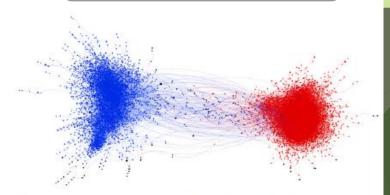
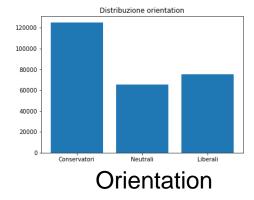
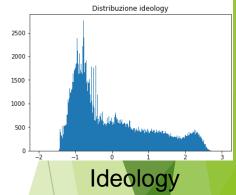


Fig. 3. Network graph of moral contagion shaded by political ideology. The graph represents a depiction of messages containing moral and emotional language, and their retweet activity, across all political topics (gun control, same-sex marriage, climate change). Nodes represent a user who sent a message, and edges (lines) represent a user retweeting another user. The two large communities were shaded based on the mean ideology of each respective community (blue represents a liberal mean, red represents a conservative mean).

- Di ogni utente si conoscono diverse caratteristiche, per il nostro progetto useremo le colonne di:
 - «user.id_str»;
 - «text»;
 - «ideology».
- L'orientamento politico del nodo è definito dal valore di ideology, i valori negativi sono associati a utenti conservatori e i valori positivi a utenti liberali. Maggiore è il modulo, più forte è l'opinione.
- In seguito ho definito l'Orientation come una versione discretizzata dell'ideology:
 - +1 ai nodi liberali;
 - 0 ai nodi neutrali;
 - -1 ai nodi conservatori.







Raw data

id_str ▼ timestamp ▼ retweeted_status.id_str ▼ user.id_str ▼ user.screen_name ▼ user.location ▼ user.description text user.followers_count user.verified contains.url contains.media ideology

Numero

Utenti

Introduzione al modello

- Il modello consiste nella combinazione di:
 - Modello di Ising;
 - Modello Preferential attachment.
- Ogni nuovo nodo che viene inserito effettua un collegamento con un nodo già esistente, con probabilità $P_k(t)$ e cessa di effettuare i collegamenti una volta che arriva al valore massimo (r_{max}) .
- Il processo continua per ogni nuovo nodo che entra nel network e si ferma una volta raggiunto il volume desiderato.
- Il nostro modello è indiretto e senza pesi.

Il modello utilizzato

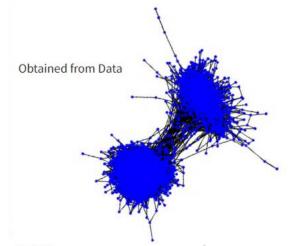
$$P_k(t) = \frac{e^{-\beta\sigma_0\sigma_k}K_k(t)}{\sum_j e^{-\beta\sigma_0\sigma_j}K_j(t)}$$

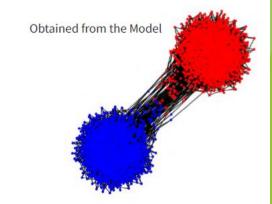
Modello Preferential attachment

$$P_i = \frac{k_i}{\sum_j k_j}$$

Modello di Ising

$$P_{\beta(\sigma)} = \frac{e^{-\beta \sum_{\langle i j \rangle} J_{ij} \sigma_i \sigma_j - \mu \sum_j h_j \sigma_j}}{\sum_{\sigma} e^{-\beta \sum_{\langle i j \rangle} J_{ij} \sigma_i \sigma_j - \mu \sum_j h_j \sigma_j}}$$





La polarizzazione

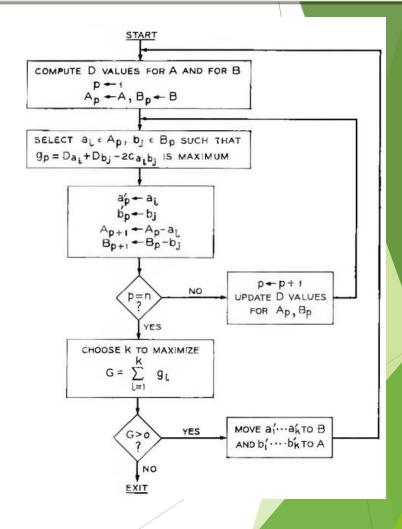
- Per definire la polarizzazione dobbiamo stabilire un modo per individuare i due poli del sistema.
- Per fare ciò utilizziamo l'algoritmo Kerninghan-Lin Bisection.
- Definiamo la quantità m, cioè la forza di ogni community, come:

$$m_j = \frac{\sum_i \sigma_{i,j}}{|c_j|}$$

Quindi definiamo la polarizzazione come:

$$Pol = \sigma^2\{m_1, m_2\}$$

Flowchart della Kerninghan-Lin Bisection



I vari casi da studiare

L'accordo con i dati

- Per effettuare l'accordo con i dati bisognerà, come prima cosa, comprendere quale caso andare a studiare. La scelta ricade sul caso «Menzioni + Retweets con nodi neutrali», in quanto l'assenza dei nodi neutrali porta ad un maggiore numero di isole, quindi ad una conseguente diminuzione dei nodi liberali e conservatori.
- Per effettuare l'accordo con i dati occorrerà utilizzare la discesa del gradiente, definendo anche il parametro di decadimento α e la funzione di Loss.

	Numero di isole	Polarizzazione	
Menzioni + Retweets con nodi neutrali	286	0,56 ± 0,03	
Menzioni + Retweets senza nodi neutrali	605	0,62 ± 0,02	
Menzioni con nodi neutrali	135	$0,001 \pm 0,003$	
Menzioni senza nodi neutrali	452	0,004 ± 0,002	

La discesa del gradiente

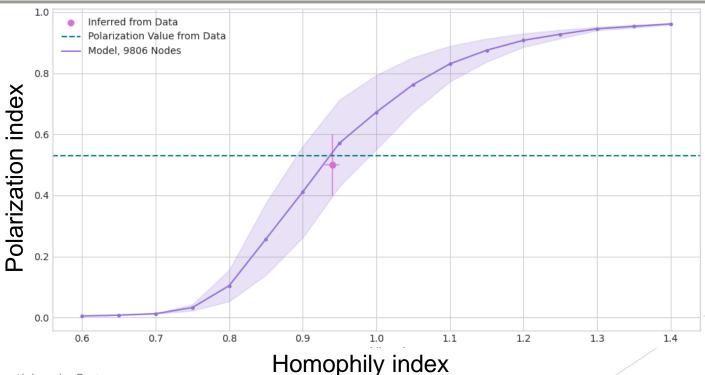
$$L = (\frac{1}{k} \sum_{i}^{k} pol_{mod,i} - pol_{spe})^{2} \qquad pol_{target} = \frac{1}{k} \sum_{i}^{k} pol_{mod,i} \qquad \alpha \propto \frac{1}{t}$$

$$\frac{dL(\beta)}{d\beta} = \lim_{\epsilon \to 0} \frac{(pol_{spe} - pol_{target}(\beta + \epsilon))^{2} - (pol_{spe} - pol_{target}(\beta))^{2}}{\epsilon} \qquad \beta^{(n+1)} = \beta^{(n)} - \alpha \frac{dL(\beta^{(n)})}{d\beta}$$
 everal Network and Big Data - Aleksandar Fontana

L'accordo con i dati

• Ho quindi variato il valore di omofilia, β , così da far combaciare il valore di polarizzazione del modello con i dati sperimentali.

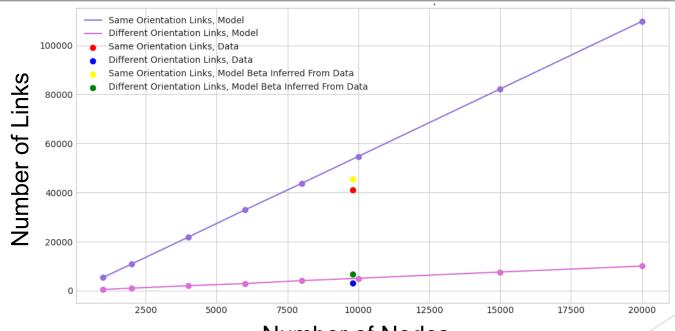
Variazione del coefficiente di Polarizzazione rispetto al valore di Omofilia (Modello e dati)



Confronto tra same orientation link e different orientation link

- Raggiunto l'accordo del modello con i dati sperimentali in relazione al valore di polarizzazione, si vuole cercare di studiare altri parametri.
- Si procede pertanto allo studio del numero dei collegamenti tra nodi con la stessa ideologia e nodi con ideologia diversa.

Numero di nodi rispetto al numero di collegamenti per l'orientation



Nuovi modelli

- Poiché, confrontandolo con i dati sperimentali, il modello non riesce a determinare il corretto numero di collegamenti tra nodi con la stessa ideologia e nodi con ideologia diversa, ho studiato diversi metodi per ottenere una migliore corrispondenza:
 - come prima cosa ho posto che r_{max} vari dinamicamente con t seguendo una distribuzione di probabilità;
 - ho quindi provato a generalizzare il modello proposto sfruttando il modello di Heisenberg al posto del modello di Ising;
 - infine ho generalizzato il modello ponendo una potenza sulla parte di Preferential attachment.

Variazione del coefficiente di Polarizzazione rispetto al valore di Omofilia (Con base modello di Heisenberg)



Modello di Heisenberg

$$P_{\beta(\sigma)} = \frac{e^{-\beta \sum_{\langle i j \rangle} \overline{J_{ij}} \overline{\sigma_i \sigma_j} - \mu \sum_j h_j \sigma_j^z}}{\sum_{\sigma} e^{-\beta \sum_{\langle i j \rangle} \overline{J_{ij}} \overline{\sigma_i \sigma_j} - \mu \sum_j h_j \sigma_j^z}}$$

Nuovi modelli

• Per lo studio della variazione di r_{max} ho scelto una distribuzione Normale ($\mu = 2,97$, $\sigma^2 = 1$) e una distribuzione di Poisson ($\lambda = 2,28$).

Modello Generalizzato

$$P_k(t) = \frac{e^{-\beta \sigma_0 \sigma_k} k_k^s(t)}{\sum_j e^{-\beta \sigma_0 \sigma_j} k_j^s(t)}$$

Tabella studio collegamenti nodi con ideologia simile e diversa

	Polarizzazione	Collegamenti tra nodi con stessa Orientation	Collegamenti tra nodi con diversa Orientation
Dati sperimentali	$0,56 \pm 0,03$	41118	3078
Modello Base, Distribuzione Normale	0.5 ± 0.2	40300 ± 100	3740 ± 60
Modello base, Distribuzione Poisson	0.5 ± 0.2	40000 ± 300	4000 ± 100
Modello generalizzato, Distribuzione Normale	0.5 ± 0.2	41000 ± 500	3300 ± 500
Modello generalizzato, Distribuzione Poisson	0.5 ± 0.2	41300 ± 500	3100 ± 400

Punti critici del modello rispetto ai dati sperimentali

- Il modello e le tecniche proposte presentano alcuni punti critici:
 - l'assenza di nodi neutri;
 - l'impossibilità di usare un modello diretto e con pesi;
 - la divisione in community data dalla bisezione di Kerninghan-Lin, non ottimale per il nostro studio.

Neural Network and Big Data - Aleksandar Fontana

Confronto con il modello «Polarizing indipendent cascade»

L'algoritmo PIC

```
Algorithm 1: PIC
```

```
-G = (V, E): An undirected graph representing a set of connected users
    -Q = \{q_u \in [-1,1], u \in V\}: The set of every node's opinion
    -C = \{c_{uv}, (u, v) \in E\}: The set of every edge's connection strength
    -I = \{i_i \in [-1,1], 1 < i < T\}: The set of every simulated news items' opinion score
    -S = \{s_i, 1 < i < T\}: The set of initial spreader nodes for every news item

    η: The update rate for opinion and connection strength

    B, μ: Parameters for the logistic function (optional)

Procedure:
for i = 1 to T do // For every news item
    /* Initialize variables:
         - t: current time step, set to 1 at the beginning of every news item's spread
         - A_t^i: the set of nodes that can still spread news item i at t
         - Infi: the set of nodes that have been infected by news item i
    t \leftarrow 1:
    A_t^i \leftarrow S_i;
    Inf^i \leftarrow Inf^i \cup S_i:
    while A_i^i \neq \emptyset do
        for u \in A_t^i do // While an active node exists
             for v: e_{uv} \in E, v \notin Inf^i do // Spread to uninfected neighbors
                 if Random() < P_{uv}(q_v, c_{uv}, i_i) then
                      // Neighbor become infected and active
                      Inf^i \leftarrow Inf^i \cup \{v\};
                      A_{t+1}^i \leftarrow A_{t+1}^i \cup \{v\} ;
                      // Opinion shifts and connection strengthens
                      q_v \leftarrow U_q(u_v, i_i, \eta) = q_v + (\eta \times sign(i_i - q_v));
                      c_{uv} \leftarrow U_c(q_{uv}) = c_{uv} + \eta;
                      // Connection weakens
                      c_{uv} \leftarrow U_c(q_{uv}) = c_{uv} - \eta;
                 end
             end
        // Go to next time step
end
```

Il loro termine di omofilia

$$\overline{\text{hom}}_{w} = \frac{\sum_{e(u,v)} c_{uv} q_{u} q_{v}}{\sum_{e(u,v)} c_{uv}}$$

Alcuni grafi simulati con il PIC

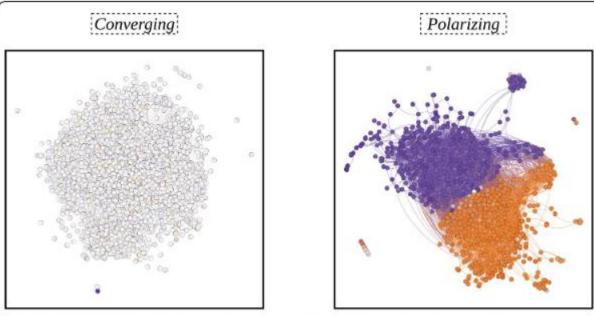
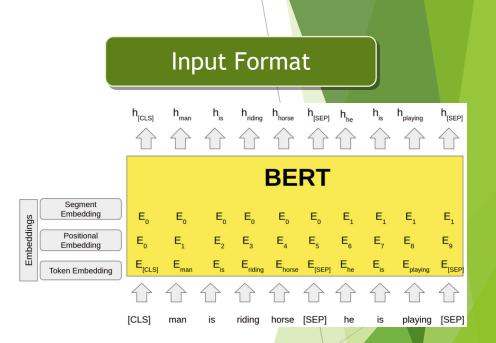


Fig. 12 Strong graph visualization of the same two simulation instances after the final cascade

Machine Learning - Google BERT

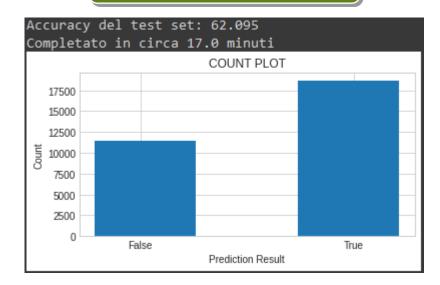
- Abbiamo sviluppato diversi modelli di Machine Learning con l'obbiettivo di assegnare un Orientation ad un qualunque utente estraneo al training set. In particolare mi sono concentrato sullo studio del modello Google BERT.
- BERT è l'acronimo di Bidirectional Encoder Representations from Transformers ed è un tipo di rete neurale pre-trainata molto utilizzata nell'ambito del linguaggio naturale. Il modello presenta circa 110 milioni di parametri ed è stato pre-trainato con un dataset di circa 3,3 Miliardi di parole.
- È stato quindi necessario andare a modificare i dati di input così da farli combaciare con quelli richiesti da BERT.



Google BERT - i risultati

- Ho effettuato quindi l'operazione di Fine Tuning assicurandomi di usare il maggior numero di testi disponibili.
- Dopo 2 ore di fine tuning alla fine i risultati di accuracy sul test set sono del 62%.

Risultati



Dataset usato

Training Set					
	Text	Ideology			
0	Better Dead than Red! RT @tomemurtha Bill Gate	1			
1	World's climate pledges not yet enough to avoi	0			
2	Ted Cruz: Climate change is not science, its	1			
3	Activists Who Are Putting Their Bodies On The	0			
4	Yet another lunatic fortune-teller worshiping	1			
		• • •			
22154	6	1			
22155	6	0			
22156	··· e··· ··· e··,	1			
22157 22158	-6	0 1			
22158	RI @danmericachn: Clinton lists Climate Chang	1			
[2215	9 rows x 2 columns]				
Test Set					
	Text	Ideology			
0	RT @enbclimate: .@OECD Publishes 2015 Indicato	0			
1	RT @drawandstrike: @danmericaCNN @JammieWF "Lo	1			
2	RT @mr bellis: Let's all stop and smell [look	0			
3	RT @FreemarketJay: Climate change catastophism	1			
4	RT @NSunners: Today's dose of laughter comes f	0			
9492	My second 500-year rain/flood event in the pas	0			
9493	#NewYork AG going after #ExxonMobil over #clim	1			
9494	RT @TEDTalks: "Climate change is the greatest	0			
9495	RT @redsteeze: When Obama talks about dangers	1			
9496	Er, please to explain? https://t.co/SClQomUGtB	0			
[0/07	rows x 2 columns]				
[949/	TOWS X Z COTUMITS]				

Conclusione

- Ciò che ho appreso grazie a questo progetto è:
 - come fare un'analisi completa e approfondita dei dati grezzi di uno studio;
 - i metodi di validazione di un proprio modello con i dati sperimentali;
 - come trovare le criticità del proprio approccio e cercare di superarle.
- Il confronto con il modello PIC mi ha permesso di conoscere un nuovo metodo di approccio alla modellizzazione della polarizzazione nei social media, metodo la cui utilità, già comprovata nell'ambito social, potrebbe, auspicabilmente, rivelarsi altrettanto valida nel campo della fisica.
- In conclusione lo studio del modello Google BERT mi ha permesso di comprendere come funzionano alcuni dei più moderni modelli di machine learning, insegnandomi allo stesso tempo che non sempre il modello più complesso è il migliore.

Neural Network and Big Data - Aleksandar Fontana